Учтив

Полная программа

AI-архитектор

Продуктивная

Для специалистов среднего, 200 часов

Модуль 1. Стратегический фундамент и планирование проекта

Тема 1
Роль AI-архитектора в работе с заказчиком. Анатомия проекта

Кто такой AI-архитектор и почему его роль отличается от роли разработчика. Как выглядит типовой проект: от первого звонка заказчика до передачи готового решения. Ошибки, которые совершают новички, и как их избежать.

Тема 2
Сбор требований и аудит бизнес-процессов

Как задавать вопросы, которые заказчик не ожидает. Интервьюирование, картирование бизнес-процессов, выявление скрытых потребностей. Как отличить реальную боль от «хотелки».

Тема 3
Оценка рентабельности и выбор подхода: build vs buy

Как посчитать, стоит ли вообще делать AI-решение. Расчет ROI, сравнение стоимости разработки, покупки и аренды. Когда не нужен AI вообще.

Тема 4
Стратегия внедрения и метрики успеха

Как измерить, что решение реально работает. Бизнес-метрики, технические метрики, пилотная фаза, A/B-тесты, сценарий отказа. Как не «зарезать» проект на последнем метре.

Дополнительно

Разработка стратегии, оценка рентабельности и метрики успеха. 4 часа

Модуль 2. Проектирование и документирование архитектуры

Тема 5
Выстраивание архитектуры: от монолита к микросервисам

Как выбирать между монолитом, микросервисами и event-driven архитектурой. Как не переусложнить простую задачу. Как эволюционировать архитектуру, когда бизнес-требования меняются.

Тема 6
Проектирование API и интеграций

Как спроектировать API, которым будут пользоваться другие разработчики. Версионирование, документирование, обработка ошибок. Как интегрировать AI-сервис с legacy-системами.

Тема 7
Выбор технологий: LLM, векторные базы, фреймворки

Как выбрать LLM-провайдера: OpenAI, Anthropic, open-source модели. Векторные базы данных: Pinecone, Weaviate, pgvector. Фреймворки: LangChain, LlamaIndex, Haystack. Как не привязаться к одному вендору.

Тема 8
Проектирование RAG-пайплайна

Как устроен RAG: индексация, retrieval, augmentation, generation. Chunking, embeddings, гибридный поиск, reranking. Как оценить качество ответов и не сделать галлюцинирующий бот.

Дополнительно

Проектирование архитектуры, выбор технологий, проектирование RAG-пайплайна. 4 часа

Модуль 3. Качество, интеграции и безопасность

Тема 9
Тестирование AI-решений: метрики, golden datasets, A/B-тесты

Как тестировать то, у чего нет детерминированного ответа. Golden datasets, human evaluation, LLM-as-judge. Как измерить, что новая версия промпта лучше старой.

Тема 10
Интеграции: REST, webhooks, очереди, legacy-системы

Как интегрировать AI-сервис с CRM, ERP, 1С, мессенджерами. Webhooks, очереди сообщений, retry-логика, idempotency. Как не сломать production при обновлении.

Тема 11
Безопасность AI-решений: prompt injection, утечки данных, jailbreak

Как защитить систему от prompt injection и jailbreak. Утечки данных через контекст модели. Как не дать пользователям использовать ваш бесплатный ChatGPT за ваши деньги.

Тема 12
Production-готовность: мониторинг, логирование, fallbacks

Что должно быть в production: мониторинг, логирование, алерты, fallbacks, graceful degradation. Как понять, что модель начала деградировать.

Дополнительно

Тестирование AI-решений, интеграции, безопасность, production-готовность. 4 часа

Модуль 4. Инфраструктура

Тема 13
Docker и docker-compose: контейнеризация AI-сервисов

Как упаковать AI-сервис в Docker. Multi-stage builds, оптимизация размера образа, кэширование слоев. Как запустить локально за 5 минут.

Тема 14
Kubernetes: Helm-чарты, ресурсы, autoscaling

Как развернуть AI-сервис в Kubernetes. Helm-чарты, ресурсные лимиты, HPA, autoscaling по custom metrics. Как не сжечь бюджет на облаке.

Тема 15
CI/CD для AI-сервисов: тесты промптов, деплой моделей, rollback

Как автоматизировать тестирование промптов. Деплой новой версии модели. Rollback при деградации. Как не выкатывать сломанный промпт в production.

Дополнительно

Docker, Kubernetes, CI/CD, деплой AI-сервисов в production. 4 часа

Тема 16
Мониторинг: Prometheus, Grafana, Langfuse, Sentry

Какие метрики собирать: latency, token usage, cost, quality. Langfuse для трейсинга LLM-вызовов. Sentry для ошибок. Как построить дашборд, который видит инженер и CTO.

Тема 17
Оптимизация стоимости: кэширование, batching, выбор модели

Как снизить расходы на токены в 3–5 раз. Кэширование ответов, batching запросов, выбор модели по задаче. Как не потратить бюджет месяца за ночь.

Тема 18
Multi-tenancy: изоляция данных, квоты, биллинг

Как обслуживать несколько клиентов на одном сервисе. Изоляция данных, квоты, rate limiting, биллинг по токенам. Как не дать одному клиенту положить всем остальным.

Дополнительно

Мониторинг, оптимизация стоимости, multi-tenancy. 4 часа

Модуль 5. Продвинутые архитектурные паттерны

Тема 19
Агентные системы: ReAct, function calling, tool use

Как устроен агент: цикл ReAct, function calling, tool use. Как ограничить агента, чтобы он не зациклился и не сжег бюджет. Когда агент вообще не нужен.

Тема 20
Multi-agent системы: CrewAI, AutoGen, LangGraph

Когда один агент уже не справляется и нужна команда агентов. Сравнение CrewAI, AutoGen, LangGraph. Как не превратить систему в хаотичный чат ботов.

Тема 21
Fine-tuning: когда дообучать модель, а когда хватит промптов

Когда fine-tuning дешевле промптов. Как подготовить датасет. Как не испортить модель на старых задачах. Как оценить, стоит ли оно того.

Тема 22
Self-hosted LLM: open-source модели, vLLM, Ollama, llama.cpp

Когда облачные API — плохая идея. Open-source модели: Llama, Mistral, Qwen. Как развернуть свою модель. Сравнение vLLM, Ollama, llama.cpp.

Дополнительно

Агентные системы, multi-agent, fine-tuning, self-hosted LLM. 4 часа

Модуль 6. Стратегия, лидерство и экономика

Тема 23
Оценка проектов: ROI, payback, стоимость владения

Как посчитать, стоит ли проект вообще. Расчет ROI, payback period, total cost of ownership. Как не обещать заказчику фантастическую экономию.

Тема 24
Product-мышление: как не сделать технологию ради технологии

Как отличить полезную фичу от технологии ради технологии. Как измерить ценность AI-фичи для пользователя. Как не строить то, что никому не нужно.

Тема 25
Роадмап и стратегия внедрения

Как выстроить последовательность внедрения AI в компании. Quick wins vs long bets. Как не сжечь бюджет на первом месяце. Как показать прогресс за квартал.

Дополнительно

Product-мышление, роадмап, стратегия внедрения. 4 часа

Модуль 7. Проектная работа

Тема 26
Выбор темы и постановка задачи

Выбор задачи, в которой вы хотите разбираться. Как сузить тему до реалистичного MVP. Что не стоит брать в дипломный проект.

Тема 27
Проектирование архитектуры

Выбор стека, диаграммы, ADR. Как обосновать каждое решение. Как показать, что вы понимаете trade-offs, а не просто копируете примеры.

Тема 28
Реализация и сдача проекта

Code review, финальная презентация, ответы на вопросы. Как защитить проект перед экспертом. Что спрашивают на защите.

Дополнительно

Проектная работа

Модуль 8. Карьера и трудоустройство

Тема 29
Резюме, портфолио, GitHub, LinkedIn

Как оформить GitHub так, чтобы на вас обратили внимание. Что должно быть в README. Как выглядит сильное AI-портфолио.

Тема 30
Собеседования: system design, live coding, take-home assignment

Как проходят собеседования на AI-инженера. Типы заданий: system design, live coding, take-home assignment. Как не провалить простую задачу.

Тема 31
Зарплаты, рынок, как искать первую работу

Сколько платят AI-инженерам в России и мире. Junior, middle, senior. Как искать первую работу, если у вас нет опыта в production.

Дополнительно

Резюме, собеседования, поиск работы. 4 часа