

Стратегия AI-персонализации для ритейлера (рекомендательная система)

Документ: вопросы, контрактная модель, матрица рисков и дорожная карта PoC → MVP → Production.

1. Контекст и допущения

Предполагается крупный омниканальный ритейлер с каталогом 50k–500k SKU, каналами web/app, историей покупок и кликов, CRM-данными и промо-активностями. Цель — рост конверсии, среднего чека и удержания через персонализированные рекомендации.

2. Уточняющие вопросы (5–7)

- Какие бизнес-метрики считаются ключевыми: CR, AOV, GMV, маржинальность, удержание?
- Где именно нужны рекомендации: главная, PDP, корзина, e-mail/пуши, офлайн-каналы?
- Какие источники данных доступны и в каком качестве: покупки, клики, поисковые запросы, возвраты, промо?
- Насколько допустимы эксперименты на пользователях и какой формат A/B-тестов предпочтителен?
- Какие требования по комплаенсу: GDPR/152-ФЗ, хранение ПИ, согласие на персонализацию?

3. Выбор модели контракта

Этап	Модель	Обоснование и выгода сторонам
PoC 4–6 недель	T&M with cap	Высокая неопределенность по данным и метрикам. T&M дает гибкость в исследованиях, cap ограничивает бюджет клиента. Для интегратора — возможность честно оценить сложность, не занижая фикс.
MVP 8–12 недель	Гибрид: FP за интеграции + T&M за ML/R&D	Интеграции и инфраструктура достаточно предсказуемы (FP), а ML-компонента все еще требует итераций (T&M). Клиент получает бюджетный контроль, интегратор — возможность улучшать качество без штрафов за смену подхода.
Production постоянно	SLA/опорный FP + T&M на развитие	Эксплуатация и поддержка фиксируются по SLA, развитие и оптимизация — по T&M для гибкой реакции на новые данные и бизнес-цели.

4. Матрица рисков (AI-специфичные)

Риск	Вероятность	Влияние	Митигация
Низкое качество данных (шум, дубли, неполные события)	Высокая	Высокое	Data profiling, каталог источников, правила очистки, мониторинг полноты событий.
Слабое покрытие рекомендаций из-за «холодного старта» (новые товары/пользователи)	Средняя	Высокое	Контентные фишки, популярные/трендовые fallback, onboarding-вопросы.
Смещение и деградация качества из-за сезонности/промо	Средняя	Среднее	Переобучение по расписанию, мониторинг дрейфа, корректировка фишек промо.
Фидбэк-луп: система усиливает одни категории и снижает разнообразие	Средняя	Среднее	Diversity/novelty метрики, бизнес-ограничения, периодическое «разнообразие».
Несовпадение оффлайн-метрик с бизнес-эффектом в онлайн	Средняя	Высокое	Согласование KPI, A/B-тесты, guardrail-метрики (маржа, возвраты).
Невыполнение SLA по латентности/масштабируемости	Средняя	Высокое	Кэширование, двухуровневые модели (candidate + ranker), нагрузочное тестирование.
Комплаенс и PII (152-ФЗ/GDPR) ограничивают персонализацию	Низкая	Высокое	Псевдонимизация, управление согласиями, минимизация PII в ML-фичах.

5. Дорожная карта и критерии успеха (DoD)

Этап	Цели и ключевые работы	DoD / критерии успеха
РoC 4–6 недель	Проверка гипотезы персонализации. Сбор выборки данных, базовая модель (например, item2item/ALS), оффлайн-оценка, прототип выдачи.	- Доступны данные и pipeline их подготовки. - Оффлайн-метрики выше базового (например, +10–20% к NDCG/Recall). - Сформирован план A/B-теста и целевые метрики.
MVP 8–12 недель	Интеграция с витринами (web/app), запуск онлайн-эксперимента, базовая аналитика, мониторинг качества и латентности.	A/B-тест на 5–20% трафика с измеримым uplift по CR/AOV.

Этап	Цели и ключевые работы	DoD / критерии успеха
		• Стабильная латентность и SLA на выдачу. • Документирована модель и процесс переобучения.
Production 12+ недель	Масштабирование на все каналы, автоматизация MLOps, управление версиями, регулярные A/B-тесты, оптимизация маржинальности.	• Раскатка на 100% трафика с устойчивым бизнес-эффектом. • Наблюдаемость: мониторинг качества, дрейфа, алерты. • Описан процесс развития и backlog улучшений.

6. Итог

Предложенный подход снижает риски неопределенности на PoC, обеспечивает контролируемый бюджет на MVP и создает основу для масштабирования в Production с понятными SLA и метриками.